

MAGÍSTER EN DATA SCIENCE

Universidad del Desarrollo

Big Data y Cloud Computing

PROYECTO INTEGRADOR

Código: MDSC3S141-1

Docente: Prof. Luis Castillo Faune

Lanzamiento: Sesión 2 : 15 de mayo de 2026

Defensa oral: Sesión 8 : 3 de julio de 2026

1. Descripción General del Proyecto

El proyecto integrador es la evaluación central del curso. Su propósito es que cada equipo diseñe, implemente y defienda una solución de Big Data y Cloud Computing sobre un problema real o realista de su elección, aplicando de forma integrada las competencias desarrolladas a lo largo de los siete módulos del curso.

El proyecto no es un ejercicio de programación: es un ejercicio de arquitectura y criterio técnico-económico. El código importa en la medida en que demuestra que la arquitectura propuesta puede implementarse y que las decisiones de optimización tienen sustento empírico. La defensa oral ante un panel simulado de stakeholders técnicos y de negocio es el momento donde todas las decisiones del proyecto se ponen a prueba.

2. Calendario de Hitos

Sesión	Fecha	Módulo	Hito del proyecto
3	29 mayo	Procesamiento Distribuido con Apache Spark	Entrega Fase 1: Propuesta arquitectónica
5	12 junio	Optimización, Rendimiento y Gestión de Costos	Entrega Fase 2: Implementación y optimización
7	26 junio	Comunicación Técnica y Decisión Arquitectónica	Entrega Fase 3: Documentación técnica
8	3 julio	—	Defensa oral ante panel simulado

3. Elección del Problema

El proyecto puede abordar un problema de cualquier sector (retail, banca, salud, minería, telecomunicaciones, agroindustria, sector público u otro) siempre que cumpla los siguientes criterios mínimos:

- **Escala justificada:**

*El problema debe involucrar un volumen, velocidad o variedad de datos que haga necesario el uso de arquitecturas de Big Data. El volumen mínimo recomendado para que las decisiones de particionamiento, formato de tabla y optimización de Spark tengan impacto real y medible es de al menos **10 millones de filas o 5 GB de datos en la capa bronce** (ej. "procesamiento de streams de logs que saturan la memoria RAM estándar"). Por lo tanto, un problema resoluble con pandas en un laptop **no califica**.*

- **Caso de uso de negocio real:**

Debe existir un stakeholder real o plausible que se beneficie de la solución: un equipo de operaciones, un área de riesgo, un servicio de salud pública, etc. La solución técnica debe conectar con un resultado de negocio medible.

- **Implementable con los recursos del curso:**

La implementación debe ser ejecutable en GCP con el free trial (USD 300) o en Google Colab. No se aceptan propuestas que requieran infraestructura a la que los estudiantes no puedan acceder.

3.1 Opción A: Problema propio

Pueden traer un problema del contexto laboral actual o de una industria que los integrantes conozcan bien. Es la opción recomendada para estudiantes con experiencia en Data Engineering, MLOps o arquitectura de sistemas. Si usan datos reales, asegúrense de anonimizarlos y de tener autorización para usarlos con fines académicos.

3.2 Opción B: Evolución del taller

Pueden tomar uno de los tres sistemas trabajados en los talleres de las sesiones 1 y 2 y profundizarlo hasta el nivel de detalle requerido por el proyecto. La arquitectura grupal del taller sirve como punto de partida, pero el proyecto debe ir significativamente más allá del diagnóstico inicial.

Sistemas disponibles como punto de partida:

- **Sistema A: Retail:** plataforma de e-commerce con detección de fraude en tiempo real (< 200 ms, 2M transacciones/día).
- **Sistema B: Minería:** 500 sensores industriales, 10 TB/mes, mantenimiento predictivo con modelo ML ya entrenado.
- **Sistema C: Salud pública:** hospital público digitalizando 20 años de fichas clínicas en papel para un análisis epidemiológico anual.

3.3 Confirmación del problema

Antes de la sesión 3 (29 de mayo), un representante de cada grupo debe enviar por Canvas la lista de integrantes del equipo y un mensaje de máximo 200 palabras indicando el problema elegido, el sector, el stakeholder beneficiado y una estimación del volumen de datos involucrado. El docente confirma o sugiere ajustes antes de la entrega de la Fase 1.

4. Fases del Proyecto

El proyecto se desarrolla en tres fases progresivas. Cada fase es un entregable independiente evaluado con criterios propios, pero las tres se articulan como un proyecto coherente: la Fase 2 implementa lo que la Fase 1 propone, y la Fase 3 documenta lo que la Fase 2 construye.

Fase 1: Propuesta Arquitectónica

Entrega: 29 de mayo de 2026, antes de las 18:30 (Canvas)

La propuesta arquitectónica es el documento más importante del proyecto. Define las decisiones de diseño sobre las que se construirán las fases siguientes. Una propuesta bien pensada hace que la implementación sea más rápida y que la documentación sea más fácil de escribir. Una propuesta apresurada genera retrabajo en cascada.

Contenido requerido

- Descripción del problema: contexto de negocio, stakeholder beneficiado, datos disponibles (fuentes, volumen estimado, frecuencia de actualización, tipos).
- Diagrama de arquitectura: representación visual del sistema completo, incluyendo fuentes de datos, capas de almacenamiento (bronze/silver/gold o equivalente), capa de procesamiento, capa de consumo y servicios cloud involucrados. Puede ser dibujado a mano, en draw.io, Excalidraw o cualquier herramienta de diagramación.
- Justificación de las decisiones arquitectónicas principales: patrón de procesamiento elegido (batch/streaming/lambda/kappa), formato de almacenamiento (Parquet, Delta Lake, Iceberg), modelo de servicio cloud (IaaS/PaaS/SaaS) y proveedor(es).
- Análisis de trade-offs: para cada decisión principal, indicar la alternativa descartada y por qué. La justificación debe incluir al menos un argumento técnico y uno económico.
- Riesgos técnicos identificados: al menos dos riesgos concretos con su estrategia de mitigación propuesta.
- Stack tecnológico: lista de servicios y herramientas que compondrán la solución, con su rol en la arquitectura.

Criterios de evaluación: Fase 1

Criterio de evaluación	Ponderación
Pertinencia de la arquitectura propuesta respecto al problema elegido	30%
Justificación técnico-económica de las decisiones arquitectónicas	30%
Identificación de riesgos técnicos y estrategia de mitigación	20%
Calidad de la presentación del diagrama de arquitectura	20%

 *El feedback de la Fase 1 se entrega durante el taller de proyecto de la sesión 4 (5 de junio). Puedes incorporar ese feedback en la Fase 2.*

Fase 2: Implementación y Optimización

Entrega: 12 de junio de 2026, antes de las 18:30 (Canvas)

La implementación debe demostrar que la arquitectura propuesta en la Fase 1 funciona en la práctica. No se espera una solución de producción completa, sino un pipeline funcional que ilustre las decisiones arquitectónicas clave con datos reales o sintéticos de escala comparable al problema elegido.

Contenido requerido

- Repositorio de código en GitHub o GitLab con README claro, instrucciones de reproducción y estructura organizada de carpetas.
 - Notebook de demostración: un notebook ejecutable que muestre el pipeline completo con resultados y comentarios explicativos orientados a una audiencia técnica. Este notebook debe estar dentro del repositorio en una carpeta específica (ej. /notebooks o /demo) que debe estar explícitamente referenciada en el README.
- Pipeline implementado en PySpark (u otro motor justificado), que cubra al menos ingesta desde la fuente, transformación en una o más capas, y escritura en el formato de tabla elegido (Delta Lake, Iceberg u otro).
- Evidencia de optimización: capturas de Spark UI, métricas de tiempo de ejecución antes y después de al menos una optimización (particionamiento, caching, tuning de recursos), y análisis de costo estimado usando la calculadora del proveedor cloud.
- Aplicación de gobierno y seguridad: al menos un control de acceso implementado, documentación del linaje de datos (puede ser manual) y manejo explícito de datos sensibles si el caso lo requiere.
- Recomendación: uso de una herramienta de orquestación (como Airflow o Cloud Workflows) para gestionar las dependencias del pipeline.

Criterios de evaluación: Fase 2

Criterio de evaluación	Ponderación
Correctitud funcional del pipeline (datos fluyen de extremo a extremo)	30%
Calidad del código (modularidad, manejo de errores, reproducibilidad)	25%
Evidencia de optimización con métricas cuantitativas (Spark UI, FinOps)	25%
Aplicación de gobierno y seguridad (control de acceso, trazabilidad)	20%

Fase 3: Documentación Técnica

Entrega: 26 de junio de 2026, antes de las 18:30 (Canvas)

La documentación técnica es el entregable que simula lo que un equipo de ingeniería recibiría al hacerse cargo del sistema que diseñaron. Debe ser suficientemente clara para que alguien que no participó en el desarrollo pueda entender las decisiones tomadas, operar el sistema y evolucionar la arquitectura.

Contenido requerido

- Diagrama de arquitectura final: versión actualizada y pulida del diagrama de la Fase 1, incorporando los cambios realizados durante la implementación. Nivel de detalle:

modelo C4, Nivel 2 (contenedores) o equivalente.

https://es.wikipedia.org/wiki/Modelo_C4

- Informe técnico: documento de 1.500 a 2.500 palabras que describa el problema, la arquitectura implementada, las decisiones de optimización tomadas con sus resultados medibles, y las limitaciones actuales con propuestas de evolución futura. Audiencia objetivo: un Data Engineer que se incorpora al equipo.
- **Architecture Decision Records (ADRs)**: al menos tres registros formales de decisiones arquitectónicas, siguiendo el formato estándar (contexto, decisión, alternativas consideradas, consecuencias). Las decisiones documentadas en los ADRs deben ser distintas entre sí y **pueden ser distintas** de las descritas en la Fase 1, en caso de haber cambios **durante la implementación**. Los ADRs se entregarán como un anexo al Informe Técnico y quedan fuera del conteo de palabras del informe.
- `README` del repositorio actualizado: debe incluir instrucciones de instalación y ejecución, manual de operación final y descripción de los datos de entrada y salida.

Criterios de evaluación: Fase 3

Criterio de evaluación	Ponderación
Compleitud y coherencia de los Architecture Decision Records (ADRs) actualizados.	35%
Calidad del diagrama de arquitectura final (Modelo C4 Nivel 2 o equivalente)	30%
Claridad del informe técnico (estructura, lenguaje, audiencia objetivo).	20%
Calidad del <code>README</code> del repositorio de código	15%

5. Defensa Oral

Fecha: 3 de julio de 2026

Formato: 20 a 30 minutos de presentación + 5 a 10 minutos de preguntas del panel

La defensa oral simula la presentación de una propuesta de arquitectura ante un comité de decisión compuesto por stakeholders técnicos y de negocio. El panel puede incluir al docente y evaluadores invitados. El objetivo no es que el equipo repita lo que está en los documentos entregados (el panel ya los leyó), sino que justifique las decisiones tomadas bajo cuestionamiento. **Todos los integrantes del grupo deben exponer.**

Estructura sugerida

Se sugiere a los equipos que dividan los turnos de exposición por secciones lógicas para que la narrativa sea coherente:

- 4 a 6 min: El problema y su escala: por qué este problema requiere Big Data y no una solución convencional.

- 8 a 10 min: La arquitectura: recorrido del diagrama (Modelo C4 Nivel 2) con énfasis en las 2-3 decisiones más importantes y sus trade-offs.
- 5 a 7 min: Resultados de implementación: métricas de rendimiento, costos estimados (FinOps), evidencia empírica de las optimizaciones.
- 3 a 5 min: Limitaciones y evolución futura: qué no alcanzaron a implementar y cómo evolucionaría la arquitectura con más tiempo o recursos.

Criterios de evaluación: Defensa oral

Criterio de evaluación	Ponderación
Claridad y solidez de la justificación de decisiones arquitectónicas	30%
Manejo de preguntas del panel (precisión técnica y honestidad)	30%
Comunicación de trade-offs técnico-económicos a audiencia no técnica	25%
Presentación del diagrama de arquitectura (claridad visual y narrativa)	15%

💡 *El panel puede preguntar sobre cualquier aspecto de los tres entregables. La honestidad sobre las limitaciones de la solución del equipo es valorada positivamente: es lo que marca la diferencia entre equipos de nivel junior y senior.*

6. Resumen de Evaluaciones del Proyecto Integrador

Las evaluaciones del Proyecto Integrador son colectivas y se detallan a continuación:

Componente	Ponderación Curso	Fase del proyecto
Proyecto integrador (informe + código)	30%	Fases 1 + 2 + 3 , ponderadas en partes iguales (10% c/u)
Defensa oral del proyecto	15%	Sesión 8: 3 de julio de 2026

7. Integridad Académica y Uso de IA

El uso de herramientas de IA generativa (ChatGPT, Claude, Copilot, Gemini u otras) está permitido y es bienvenido como parte del proceso de trabajo. Sin embargo, aplican las siguientes condiciones:

- **Declaración obligatoria:**

Cada entregable debe incluir una sección de máximo un párrafo declarando qué herramientas de IA utilizó el equipo y para qué. No declararlo cuando sí se usaron constituye falta de integridad académica.

- **Responsabilidad sobre el contenido:**

Los integrantes son responsables de todo lo que entregan, independientemente de si fue generado con ayuda de IA. Si el panel pregunta sobre una decisión arquitectónica o un fragmento de código de su entrega y el equipo no puede explicarlo, la evaluación lo reflejará.

- **Los datos son suyos:**

No suban a ninguna herramienta de IA datos confidenciales de una empresa. Si usan datos reales, háganlos anónimos primero.

8. ¿Cómo Obtener los Datos?

Una de las preguntas más frecuentes al comenzar un proyecto de Big Data es: ¿de dónde sacamos los datos? La respuesta corta es que no necesitas datos de una empresa para hacer un buen proyecto. Un pipeline bien diseñado sobre datos públicos a escala real puede ser más valioso pedagógicamente que uno con datos propios mal arquitectado. A continuación se describen tres estrategias, ordenadas de más a menos convenientes para el contexto de este curso.

Estrategia A: Datasets ya disponibles en BigQuery (recomendada)

Google aloja directamente en BigQuery más de 200 datasets públicos que pueden consultar sin descargar nada. Con su cuenta GCP del free trial, simplemente apunten su consulta a la tabla correspondiente y el dato ya está ahí, a escala real, sin costo de almacenamiento.

Dataset	Sector	Escala	Tabla BigQuery
NYC Taxi Trips	Retail / Transporte	~1.700M filas	bigquery-public-data.new_york_taxi_trips.*
Chicago Crime	Seguridad pública	~8M filas	bigquery-public-data.chicago_crime.crime
NOAA Weather	Medioambiente / Agroindustria	~1.000M filas	bigquery-public-data.noaa_gsod.*
Medicare / Medicaid	Salud	~100M filas	bigquery-public-data.cms_medicare.*
GitHub Activity	Tecnología	~3 TB	bigquery-public-data.github_repos.*
Stack Overflow	Tecnología / Educación	~50M posts	bigquery-public-data.stackoverflow.*
GDELT (noticias globales)	Medios / Análisis	~500 GB/año	bigquery-public-data.gdelt_v2.*
Wikipedia	NLP / Medios	~6M artículos	bigquery-public-data.wikipedia.*

Estrategia B: Repositorios de datos abiertos

Para proyectos que requieren simular un pipeline de ingesta desde una fuente externa, o que necesitan datos de un dominio no cubierto por BigQuery Public Datasets:

Kaggle Datasets: kaggle.com/datasets

Miles de datasets, muchos con decenas de millones de filas. Kaggle permite descargar directamente a GCP vía su API, lo que convierte la descarga en parte del pipeline de ingesta. Útil para datos de retail, sensores industriales, datos hospitalarios anonimizados y series de tiempo financieras.

Datos abiertos de Chile y región

- datos.gob.cl: Portal oficial del Estado de Chile. Datos de salud pública, transporte, medio ambiente, educación y estadísticas económicas.
- CEPAL / Banco Mundial: Series económicas y sociales de largo plazo para Latinoamérica. Útil para proyectos de análisis histórico con múltiples fuentes.
- INE Chile (inec.cl): Censos, encuestas de empleo, índices de precios.

Hugging Face Datasets: huggingface.co/datasets

Referencia principal para datos de texto e imágenes a escala. Útil si el proyecto involucra procesamiento de datos no estructurados: logs, registros clínicos en texto libre, datos de redes sociales.

Estrategia C: Datos sintéticos generados

Para proyectos donde tienen un problema claro pero no pueden acceder a los datos reales. Por ejemplo, si alguno de los integrantes trabaja en banca y el equipo quiere modelar detección de fraude sin usar datos reales, la solución es generar datos sintéticos que repliquen la estructura y distribución estadística del problema real. Esta estrategia es completamente válida para el proyecto integrador, siempre que el volumen generado sea suficiente para que las decisiones de arquitectura tengan impacto medible (al menos 10 millones de filas o 5 GB, como se menciona en la Sección 3).

Herramientas recomendadas:

- **Faker (Python)**: genera datos personales, transaccionales y de logs. Fácil de integrar en un pipeline de ingesta. Ideal para simular flujos de eventos a escala.
- **SDV, Synthetic Data Vault (Python)**: genera datos sintéticos que preservan las correlaciones estadísticas de una muestra real. Útil si tienen acceso a una muestra pequeña (1.000 filas) pero necesitan escalarla a millones.
- **DBLDTAGEN (Databricks)**: generador integrado con Spark, diseñado para producir decenas de millones de filas con distribuciones controladas directamente en el cluster. Disponible en Databricks Community Edition.

💡 La ventaja de los datos sintéticos es que controlas exactamente el volumen, la distribución y la complejidad. Eso facilita diseñar experimentos de optimización con resultados predecibles y comparables.

¿Cómo elegir la estrategia correcta?

Si la situación es...	Estrategia recomendada
No tienen datos propios ni un problema específico en mente	Estrategia A: Elegir un dataset de BigQuery Public Datasets y construye el problema alrededor de él
Tienen un problema claro pero no los datos	Estrategia C: Generar datos sintéticos que repliquen la estructura del problema
Tienen un problema y datos reales de una empresa	Estrategia B: Anonimizar los datos y úsalos. Declarar que son datos propios anonimizados
Hicieron el taller con el Sistema A, B o C y quieren profundizarlo	Estrategia A + C :Ejemplos: Retail Sales Dataset (Sistema A), NOAA Weather o sintéticos de sensores (Sistema B), o datos.gob.cl (Sistema C)

9. Canal de Comunicación

Consultas sobre el proyecto:

Canal principal: Mensajería interna de Canvas (tiempo de respuesta: 48 horas hábiles).

Consultas urgentes: Durante los talleres de proyecto de las sesiones 4 y 5, el docente está disponible para revisión en tiempo real.